

Implementación de Vision Transformers (ViT) en Modelos Automatizados de Valuación (AVM)

De la Ceguera de los Datos a la Inteligencia Visual Multimodal

Evolución del Mercado


El AVM global proyecta un crecimiento a **\$18.7B USD (2034)** con adopción **>68%** en originación hipotecaria, reduciendo costos operativos en un **22%**.

Paradigma Actual


Transición definitiva de modelos de precios hedónicos (HPM) a IA Multimodal (Texto, Estructura, Imagen).

Objetivo Core

Reducir la varianza de error de valuación integrando representaciones latentes de características visuales y espaciales.



El Punto Ciego de la Econometría Tradicional



Falla de Heterogeneidad

Dos propiedades con idénticos metros cuadrados y antigüedad difieren abismalmente en su estado de conservación (C1-C6) y calidad de acabados.

Márgenes de Error Históricos

La dependencia de heurísticas humanas y omisión visual genera márgenes de error de hasta el 30% en valuaciones tradicionales.


Auto-Atención: Decodificando la Composición Arquitectónica

Una imagen vale 16x16 palabras

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$



El modelo entiende el concepto global de "cocina renovada" ponderando simultáneamente todos los elementos.



- **Secuenciación Visual:** Segmentación de la imagen en parches fijos proyectados como tokens de un texto NLP.
- **Mecanismo de Auto-Atención:** Permite capturar dependencias de largo alcance sin convoluciones.
- **Modelado Global:** Cada parche consulta a todos los demás para ponderar su importancia relativa en la formación del valor estético del inmueble.

Pipeline de Visión: Estandarización de la Realidad

Capa de Protección contra Sesgo Fotográfico



Mitigación de Distorsiones

Corrección de la distorsión focal (gran angular) utilizada por corredores para exagerar dimensiones espaciales.


Homogeneización de Entrada

Normalización de exposición y saturación HDR para evaluar la calidad física real, no la iluminación del anuncio.

Invariancia de Modelado

Estrategias agresivas de augmentation para evitar el sobreajuste (*overfitting*) en conjuntos de datos limitados.

Arquitectura ViT: De Píxeles a Estimación de Valor



Linear Projection (Patch Embeddings)

Mapeo de fragmentos 2D a un espacio latente vectorial (D-dimensional). Transforma la imagen en secuencias matemáticas procesables.

Positional Encodings


Inyección topológica crítica para que el modelo preserve la geometría, diferenciando las texturas de un techo frente a las de un suelo.

Cabezal de Regresión Específico

Sustitución del clasificador categórico tradicional por una red que emite scores continuos (ej. Estado Físico de Ross-Heidecke o Valor Directo M^2).

Fusión Multimodal: Convergencia Tabular, Textual y Visual

Arquitecturas Avanzadas Trimodales



Late Fusion vs. Cross-Attention

La fusión adaptativa pondera dinámicamente el peso de la imagen vs. la tabla según la volatilidad del mercado (Alcanzando un $R^2 = 0.9029$).

Learnable Missing Tokens


Arquitectura resiliente que mantiene precisión analítica incluso cuando el inmueble carece de fotografías completas o descripciones detalladas.

Comparables como Tokens

Innovación tipo OVM: las propiedades comparables del mercado se procesan como tokens de una secuencia, calculando pesos de atención relativos.

Stack Tecnológico e Infraestructura MLOps

Viabilidad en Entornos de Producción



Transfer Learning Eficiente

Uso de modelos pre-entrenados (ViTMAE, arquitecturas CLIP) para extracción de **embeddings**, evitando el prohibitivo costo de entrenar Transformers visuales desde cero.

Infraestructura Edge vs. Cloud

Implementación de **Swin Transformers** para reducir la latencia de procesamiento cuadrático a lineal, logrando tiempos de inferencia en producción inferiores a 100ms.

Rastreo y MLOps

Uso estricto de **Weights & Biases** para rastreo de experimentos, control de hiperparámetros y prevención de memorización de anomalías (overfitting).

Caso de Estudio: Estimación de Obsolescencia Física

Aprendizaje Auto-supervisado con ViTMAE



• El Problema



Discrepancia de hasta 30% en valuaciones humanas debido a la subjetividad al evaluar la "obsolescencia funcional".

• Metodología Masked Autoencoder



El modelo reconstruye parches ocultos para aprender características estéticas intrínsecas de forma autónoma, sin necesidad de etiquetado manual.

• Resultados Clínicos



Reducción drástica del RMSE. El ensamble visual eleva el R^2 a >0.85 , reduciendo directamente la exposición al riesgo crediticio del portafolio.


Abriendo la Caja Negra: Evidencia Pericial y XAI

Mapas de Atención y Transparencia Algorítmica Financiera

Fotografía Original



Mapa de Atención ViT



Explicabilidad Exigida (XAI)

Cumplimiento estricto de las normativas de transparencia algorítmica y prevención de sesgos para la mitigación del riesgo de crédito institucional.

Attention Rollout

Extracción topológica de las capas del Transformer para identificar de forma precisa qué parches visuales impulsaron el valor del activo al alza o a la baja.

Análisis SHAP Multimodal

Cuantificación probabilística exacta: desglosa ante un auditor cómo la "humedad detectada" o una "remodelación premium" ajustaron el precio base predicho por el catastro.

Conclusiones y Roadmap de Despliegue en AVMs

Hacia la Valuación Multimodal Determinista

